Cayetano Soriano Gallego

IA en producción, sobre plataformas que no se rompen.

CTO y arquitecto hands-on con más de 15 años en tech, 8+ en AWS y 7+ como CTO. He liderado dos transformaciones de monolito a microservicios, y hoy construyo funcionalidades con LLMs, servidores MCP y flujos de ingeniería agéntica que funcionan en producción.

hello@cayetano.dev · linkedin.com/in/csorianogallego · github.com/neoshadybeat · cayetano.dev · Madrid, Spain

15+	7+	2	99.99%
AÑOS EN TECH	AÑOS COMO CTO	MIGRACIONES MONOLITO → MICROSERVICIOS	UPTIME DE PLATAFORMA

Lo que construyo con IA

Funcionalidades LLM en productos reales

Claude generando fichas bilingües y textos SEO para un marketplace; triaje de síntomas con LLM en un producto de salud digital; OpenAI y Gemini para chat y voz a texto en un asistente de voz. Tool calling y salidas estructuradas, no chat libre.

`Claude API` `OpenAI` `Gemini` `Tool calling` `Voz a texto`

Servidores MCP y tooling para agentes

Servidores MCP que permiten a los agentes leer y actuar sobre datos de producto con seguridad, desde un servidor de administración del back office hasta uno de dominio con 7 módulos (medicación, agenda, llamadas, timeline...). Herramientas internas sobre Claude Agent SDK.

`MCP` `Claude Agent SDK` `TypeScript` `Python`

Privacidad, tests y coste por defecto

Datos personales eliminados antes de cada prompt, kill switches con feature flags y endpoints UE conmutables por GDPR; llamadas a LLM cubiertas con tests sobre un transporte de modelo falso; el modelo adecuado para cada tarea para controlar el coste; monitorización con Sentry como cualquier otro servicio.

`GDPR` `Anonimización de datos` `Feature flags` `Testing` `Sentry`

Ingeniería agéntica para equipos

Claude Code en una docena de repos con reglas de proyecto (CLAUDE.md) verificadas en CI, agentes de IA en CI/CD y actualización automática de dependencias. Como CTO, introduje flujos asistidos por LLM en el proceso de ingeniería.

`Claude Code` `CI/CD` `Dependabot` `Cursor`

Experiencia

Independiente

Abr 2026 — Actualidad

CTO fraccional, Arquitecto e Ingeniero de IA

- **CTO fraccional** y arquitecto/desarrollador hands-on para empresas en fase temprana: estrategia técnica, revisiones de arquitectura, setup cloud y de delivery.
- **enolovers.app** (cliente): carga de la app de **~10 s a menos de 1 s** (carga de recursos, datos lazy vs eager, índices en BD, caché Redis, rate limiting); generación de contenido bilingüe con **Claude** y un servidor **MCP** de administración; CI/CD con **agentes de IA**, actualización automática de dependencias y test harness; buenas prácticas de seguridad; infraestructura en **Terraform**; Sentry, monitorización, analíticas y métricas por llamada.
- **Producto propio de salud digital** (en desarrollo): triaje de síntomas con LLM eliminando datos personales, acompañante de voz con transcripción, y un **servidor MCP** con 7 módulos de herramientas.

- Formación intensiva en **seguridad, sistemas de IA/LLM, arquitectura de software y blockchain**, aplicada directamente en proyectos de clientes.

ShareTech

Mar 2023 — Apr 2026

Chief Technology Officer

- Responsable de la **visión tecnológica y el roadmap**; última palabra en arquitectura cloud, build-vs-buy e inversiones de plataforma.
- Lideré squads de ingeniería multifuncionales; definí estándares de **gobernanza de microservicios, fiabilidad y developer experience**.
- Hands-on en **automatización de infraestructura (Terraform, ECS)**, optimización de costes AWS y guardias/observabilidad con Sentry + PagerDuty.
- **Contratos con proveedores y partners** (integraciones M2M y ciberseguridad con Telefónica); interlocutor técnico con el Ayuntamiento de Pamplona.
- Herramientas de operaciones y logística: **métricas, SLAs, dashboards de reporting** y optimización de costes.
- **Observabilidad end-to-end**: instrumentación OpenTelemetry, Datadog/New Relic, CloudWatch, Kibana, Sentry y guardias con PagerDuty.
- Desarrollo backend hands-on; introduje **flujos asistidos por LLM** en el proceso de ingeniería.

Ride On

2019 — Mar 2023

Chief Technology Officer

- **Promoción de Arquitecto a CTO** para liderar toda la estrategia tecnológica de la plataforma de movilidad eSharing (en remoto desde 2020).
- Escalé la organización de ingeniería e introduje **OKRs** en el departamento técnico.
- Impulsé **arquitectura event-driven sobre AWS Kinesis**; optimicé la orquestación de contenedores en **ECS**, reduciendo el coste de infraestructura ~30%.
- Responsable directo de **uptime (99,99%), seguridad y due diligence técnica** con inversores.
- **Contratos con proveedores y partners** (M2M y ciberseguridad con Telefónica); interlocutor técnico con los ayuntamientos de **Miami, Dundee, Leicester y Pamplona**.
- Operaciones y logística: herramientas internas, métricas, SLAs y dashboards de reporting.
- **Observabilidad end-to-end**: instrumenté todos los servicios con **OpenTracing / OpenTelemetry** (distributed tracing), métricas estructuradas y alertas (New Relic, Datadog, CloudWatch, Kibana, Sentry, PagerDuty) — de la petición a la base de datos.

Ride On

2018 — 2019

Arquitecto de Software

- Lideré la re-arquitectura completa: **monolito Clojure legacy → 20+ microservicios containerizados en AWS ECS**.
- Autor de toda la capa de **Infraestructura como Código en Terraform**; CI/CD automatizado con Jenkins, imágenes con Ansible + Packer.
- Observabilidad con Sentry y PagerDuty; eliminé los cuellos de botella que impedían la **escala a nivel de ciudad**.

Kimia

2017

Arquitecto de Software

- Diseño y entrega de **servicios backend de alto rendimiento en Go**, sobre Redis y Elasticsearch.
- Pipelines de monitorización y alertas en tiempo real que mejoraron los tiempos de respuesta a incidentes y la fiabilidad.

Packlink

2015 — 2017

Backend Engineer

- Contribuidor clave en el backend de **Packlink Pro y la integración de envíos de eBay**.
- Impulsé la migración de un monolito PHP a **microservicios políglotas (Java, Scala, Python)** con RabbitMQ, Cassandra y Redis.
- **Despliegues zero-downtime** en operaciones e-commerce de alto tráfico.

- **Monitorización y guardias** de la plataforma: dashboards Kibana/Elasticsearch, CloudWatch, Sentry y PagerDuty para un producto de alta disponibilidad.

Tecnologías y habilidades

IA, agentes y LLMs

Claude / Anthropic API · OpenAI API · Gemini API · MCP (Model Context Protocol) · Claude Agent SDK · AI agents · Tool calling · Structured outputs · Prompt engineering · Speech-to-text (Whisper) · PII redaction / GDPR · Claude Code · Cursor · GitHub Copilot · Blockchain / Smart contracts

Cloud e infraestructura

AWS · Terraform · ECS · Serverless · Kong · Kinesis · SNS / SQS

Backend

Java / Spring Boot · TypeScript / Node.js · Python · Scala · PHP

Datos y almacenamiento

DynamoDB · Elasticsearch · MongoDB · MySQL · Redis / ElastiCache · Cassandra · Hadoop / Hive

DevOps, CI/CD y observabilidad

Docker · Jenkins · Ansible · Packer · Consul · OpenTelemetry / OpenTracing · Distributed tracing · Datadog · New Relic · CloudWatch · Kibana · Sentry · PagerDuty · RabbitMQ · Security hardening

Liderazgo

Estrategia tecnológica y roadmap · OKRs · Contratación y escalado de equipos · Due diligence técnica · Gestión de costes · Seguridad y respuesta a incidentes

Formación y certificaciones

Universidad de Cádiz

Ingeniería Técnica en Informática de Sistemas

2007 — 2014

Megathon W8 Cádiz

Premio hackathon

Claude Code in Action

Anthropic · 2026 · Verificar ↗